






Machine Learning - Uniesp - 09/11/2024

 Introdução à Inteligência Artificial: A aula iniciou com uma apresentação do fluxo da ciência de dados e a relevância do machine learning.

 Contexto Histórico: Discutiu-se o impacto da IA na sociedade e os desafios éticos que surgem com sua aplicação.

 Conceitos Básicos: Foi abordada a definição de machine learning, seus tipos e a importância da generalização.

 Prática de Classificação: Os alunos utilizaram o Scikit-learn para criar e treinar um modelo de árvore de decisão.

 Análise e Discussão: Os resultados do modelo foram analisados, destacando a importância das features na decisão.

Palavras Chave - Inteligência Artificial - Machine Learning - Classificação - Ética - Dados

Resumo

A Aula teórico-prática sobre Machine Learning abordou diversos aspectos fundamentais da inteligência artificial, começando com uma introdução ao fluxo da ciência de dados e a importância do Machine Learning.

Foram discutidos o contexto histórico e o impacto da IA na sociedade, além dos desafios éticos que ela enfrenta.

O encontro detalhou conceitos básicos de Machine Learning, como os tipos de aprendizado e a importância da generalização, seguido por aplicações práticas e desafios enfrentados na área, como vieses em sistemas de IA.

Os alunos aprenderam sobre técnicas e algoritmos, o ciclo de vida da ciência de dados, e participaram de uma prática de classificação utilizando o Scikit-learn, culminando na análise e discussão dos resultados obtidos.

Ao final, foram incentivados a explorar outros modelos de classificação, enquanto o professor planejou futuras aulas com foco no deployment de modelos de IA e a organização do calendário de aulas.

Notas

Introdução à Inteligência Artificial

- Apresentação do fluxo da ciência de dados
 - O fluxo da ciência de dados envolve etapas que vão desde a coleta de dados até a entrega de modelos preditivos.
 - Cada fase do fluxo é interativa e pode exigir revisões e ajustes conforme novos dados são analisados.
 - A colaboração entre diferentes profissionais, como cientistas de dados, engenheiros de dados e analistas, é fundamental para o sucesso do projeto.

-
- Foco em inteligência artificial e machine learning
 - Inteligência artificial (IA) refere-se à capacidade de máquinas e sistemas computacionais de realizar tarefas que normalmente requerem inteligência humana, como reconhecimento de voz, tomada de decisão e tradução de idiomas.
 - Machine learning (aprendizado de máquina) é um subcampo da IA que utiliza algoritmos e modelos estatísticos para permitir que as máquinas aprendam a partir de dados, melhorando seu desempenho em tarefas específicas sem serem explicitamente programadas para isso.
 - A aplicação de IA e machine learning está crescendo em diversas áreas, incluindo saúde, finanças, marketing e transporte, permitindo inovações como diagnósticos médicos automatizados, análise preditiva de mercado e veículos autônomos.
-
- Discussão sobre áreas de pesquisa: inteligência computacional e machine learning
 - Inteligência computacional é aplicada a problemas complexos que exigem soluções adaptativas e flexíveis.
 - Machine learning é uma subárea da inteligência artificial que utiliza algoritmos para aprender com dados e fazer previsões ou classificações.
 - A combinação de inteligência computacional e machine learning permite otimizar processos e melhorar a tomada de decisões em diversas áreas, como saúde, finanças e logística.

Contexto Histórico e Impacto da IA

-
- Revoluções na história da humanidade: agrícola, industrial, informação
- Sociedade da Inteligência: uso de dados para tomada de decisões
- Desafios éticos e sociais da IA
 - A inteligência artificial pode perpetuar preconceitos existentes nos dados, resultando em discriminação em decisões automatizadas.
 - A falta de transparência nos algoritmos de IA dificulta a responsabilização por decisões erradas ou injustas.
 - O uso de IA levanta preocupações sobre privacidade e segurança, especialmente com a coleta e análise de dados pessoais em larga escala.

Conceitos Básicos de Machine Learning

-
- Definição de machine learning e suas aplicações
 - Machine learning é um subcampo da inteligência artificial que se concentra em desenvolver algoritmos que permitem que os computadores aprendam a partir de dados e façam previsões ou decisões sem serem explicitamente programados.
 - As aplicações de machine learning incluem reconhecimento de voz, sistemas de recomendação, detecção de fraudes, diagnósticos médicos e análise preditiva em diversas indústrias.
 - Machine learning pode ser classificado em três tipos principais: aprendizado supervisionado, onde os dados são rotulados; aprendizado não supervisionado, onde os dados não são rotulados; e aprendizado por reforço, que utiliza recompensas e punições para treinar modelos.

-
- Tipos de aprendizado: supervisionado, não supervisionado e por reforço
 - Tipos de aprendizado supervisionado envolvem o uso de dados rotulados para treinar modelos que podem prever ou classificar novos dados com base em padrões aprendidos.
 - O aprendizado não supervisionado utiliza dados não rotulados para identificar padrões e agrupamentos dentro dos dados, sem a necessidade de uma saída específica.
 - O aprendizado por reforço é um método onde um agente aprende a tomar decisões através de recompensas e penalidades, ajustando seu comportamento com base nas consequências de suas ações.
-
- Importância da generalização nos modelos de ML
 - A generalização é crucial para garantir que um modelo de aprendizado de máquina funcione bem em dados não vistos, não apenas nos dados de treinamento.
 - Modelos que generalizam bem são menos propensos a overfitting, onde aprendem detalhes e ruídos dos dados de treinamento em vez de padrões subjacentes.
 - A capacidade de generalização permite que os modelos sejam aplicados em diferentes contextos e cenários, aumentando sua utilidade e eficácia em aplicações do mundo real.

Aplicações e Desafios da IA

- Exemplos de aplicações de IA: reconhecimento facial, chatbots, carros autônomos
- Discussão sobre vieses e discriminação em sistemas de IA
- Necessidade de explicabilidade nos modelos de IA
 - A explicabilidade é crucial para garantir a confiança dos usuários nos sistemas de IA, permitindo que eles compreendam como as decisões são tomadas.
 - Modelos de IA complexos, como redes neurais profundas, podem ser difíceis de interpretar, o que levanta preocupações sobre viés e justiça nas decisões automatizadas.
 - A necessidade de explicabilidade é especialmente importante em setores críticos, como saúde e finanças, onde as consequências de decisões erradas podem ser significativas.

Técnicas e Algoritmos de Machine Learning

- Apresentação de diferentes técnicas: árvores de decisão, redes neurais, SVM
 - Árvores de decisão são modelos de aprendizado supervisionado que utilizam uma estrutura em forma de árvore para tomar decisões baseadas em características dos dados, permitindo fácil interpretação e visualização dos resultados.
 - Redes neurais são inspiradas no funcionamento do cérebro humano e consistem em camadas de neurônios artificiais que processam informações, sendo especialmente eficazes em tarefas de reconhecimento de padrões e classificação complexa.
 - Support Vector Machines (SVM) são algoritmos de aprendizado supervisionado que buscam encontrar o hiperplano que melhor separa diferentes classes em um

espaço de alta dimensão, sendo eficazes em problemas de classificação e regressão.

-
- Discussão sobre a importância da seleção de atributos
 - A seleção de atributos é crucial para melhorar a performance do modelo de machine learning.
 - Ela ajuda a reduzir a complexidade do modelo, evitando o overfitting e melhorando a generalização.
 - A escolha adequada de atributos pode aumentar a interpretabilidade do modelo, facilitando a compreensão dos resultados.
-
- Introdução ao processo de treinamento e teste de modelos
 - O processo de treinamento envolve a utilização de um conjunto de dados rotulados para ensinar o modelo a reconhecer padrões e fazer previsões.
 - A fase de teste é crucial para avaliar a performance do modelo, utilizando um conjunto de dados separado que o modelo não viu durante o treinamento.
 - A generalização é um objetivo chave, onde o modelo deve ser capaz de aplicar o que aprendeu a novos dados, mantendo uma taxa de erro aceitável.
-

Ciclo de Vida da Ciência de Dados

- Etapas do processo de machine learning: coleta, limpeza, exploração, modelagem
 - Coleta de dados envolve a obtenção de informações relevantes de diversas fontes, como bancos de dados, APIs ou arquivos, garantindo que os dados sejam representativos do problema a ser resolvido.
 - Limpeza de dados consiste em identificar e corrigir erros, inconsistências e dados ausentes, além de remover duplicatas e formatar os dados corretamente para garantir a qualidade e a integridade das informações.
 - Exploração de dados envolve a análise inicial dos dados para entender suas características, padrões e distribuições, utilizando visualizações e estatísticas descritivas para informar decisões sobre a modelagem.
-
- Importância da preparação dos dados e balanceamento de classes
- Discussão sobre o framework CRISP-DM
-

Prática de Classificação

- Introdução ao problema de classificação
- Utilização do Scikit-learn para criar um modelo de árvore de decisão
 - O modelo é treinado utilizando um conjunto de dados rotulados, onde cada entrada é associada a uma classe.
 - Após o treinamento, o modelo pode prever a classe de novas entradas, facilitando a tomada de decisões automatizadas.
-
- Demonstração prática de treinamento e previsão com um dataset simples
-

Análise e Discussão do Modelo

- Interpretação dos resultados do modelo de classificação
- Discussão sobre a importância das features na tomada de decisão
- Reflexão sobre as limitações e potencialidades dos modelos de ML

- Modelos de Machine Learning podem apresentar viés se os dados de treinamento não forem representativos da realidade, levando a decisões injustas ou imprecisas.
- A capacidade de generalização dos modelos é crucial; um modelo que não se adapta a novos dados pode falhar em aplicações do mundo real.
- Apesar das limitações, os modelos de ML têm o potencial de automatizar processos complexos, melhorar a eficiência e oferecer insights valiosos a partir de grandes volumes de dados.

●

Explorando Outros Modelos e Técnicas

- Sugestão para explorar outros modelos do Scikit-learn
- Discussão sobre a diferença entre aprendizado supervisionado e não supervisionado
 - Aprendizado supervisionado utiliza dados rotulados, onde o modelo aprende a associar entradas a saídas específicas.
 - Aprendizado não supervisionado trabalha com dados não rotulados, buscando identificar padrões ou agrupamentos sem orientação externa.
 - O aprendizado supervisionado é geralmente usado para tarefas de classificação e regressão, enquanto o não supervisionado é utilizado para clustering e redução de dimensionalidade.
-
- Reflexão final sobre o potencial e as limitações da inteligência artificial

Ações

Alunos

- Explorar outros modelos de classificação no Scikit-learn e tentar implementá-los
 - Explorar outros modelos de classificação no Scikit-learn permite:
 - Aproveitar uma variedade de algoritmos, como SVM, árvores de decisão e regressão logística, para diferentes tipos de problemas de classificação.
 - Implementar técnicas de validação cruzada para avaliar a performance dos modelos e evitar overfitting.
 - Utilizar pipelines para simplificar o processo de pré-processamento e modelagem, facilitando a experimentação com diferentes configurações de dados e algoritmos.

Professor

- Preparar material sobre deployment de modelos de ML para futuras aulas
- Criar uma enquete no grupo para decidir sobre o calendário das próximas aulas